

Les Phases de la Partie 1

Pl@ntNet

2026-04-25

Phase 1 : Préparation et partitionnement des données

Objectif : Créer les fichiers définitifs de travail pour l'équipe à partir des fichiers JSON bruts du dataset Pl@ntNet-CrowdSWE.

Données : Fichiers JSON originaux du dataset (`ground_truth.json`, `ai_scores_all.json`).

Tâches techniques :

- **Identification Expert :** Fouiller les fichiers JSON originaux ou le fichier `observations` pour trouver le tag "Expert" ou "Botaniste". Si l'info manque, utiliser le fichier de validation (souvent considéré comme expert).
- **Scripts de partitionnement :** Écrire un script R ou Python qui génère deux types de dossiers :
 - `split_random/` : Contient `calibration_50.csv` et `test_50.csv` (après un `shuffle`).
 - `split_expert/` : Contient `calibration_crowd.csv` (données non-expertes) et `test_expert.csv` (données expertes).
- **Nettoyage :** S'assurer que les `observation_id` sont bien des clés uniques et qu'il n'y a pas de doublons entre calibration et test.

Méthodologie détaillée :

- **Conversion JSON → CSV :** Utiliser un parsing en *streaming* (`ijson`) car `ai_scores_all.json` pèse 1.8 GB et ne peut pas être chargé entièrement en mémoire avec `json.load()`.
- **Filtrage des experts :** Ne conserver que les observations avec `ground_truth_val ≥ 0` (les valeurs `-1` correspondent aux observations non validées par un expert).
- **Shuffle/Split (50%/50%) :** Diviser aléatoirement les observations expertes en un ensemble de calibration ($n = 10\,812$) et un ensemble de test ($n = 10\,812$), en garantissant l'absence de chevauchement.
- **Vérifications de cohérence :** Compter les doublons, vérifier l'unicité des `observation_id` et compter les espèces orphelines (présentes dans le test mais absentes de la calibration).

Livrable : `scripts/02_data_splitting.py` (ou `.R`).

Résultat attendu : Deux fichiers CSV équilibrés contenant les colonnes `observation_id` et `ground_truth_val`, prêts pour les phases suivantes.

Phase 2 : Implémentation de la Conformal Prediction marginale

Objectif : Implémenter la méthode d'Angelopoulos (le standard) pour obtenir la couverture marginale cible.

Données à utiliser : `calibration_50.csv`, `test_50.csv`, `ai_scores_all.csv`.

Tâches techniques :

- **Calcul des scores :** Sur l'ensemble de calibration, calculer le score de non-conformité $S_i = 1 - \hat{p}_{y_i}$ (où y_i est la vraie espèce).
- **Calcul du Quantile $\hat{q}$:** Écrire la fonction qui calcule le quantile corrigé $\frac{\lceil (n+1)(1-\alpha) \rceil}{n}$ pour $\alpha = 0.05$.
- **Génération des Ensembles :** Utiliser le fichier `ai_scores_all.csv` pour construire, pour chaque image de test, l'ensemble $\mathcal{C}(X) = \{y : \text{score}_y \geq 1 - \hat{q}\}$.
- **Métriques :** Calculer la **Couverture** (est-on bien à 95% ?) et la **Taille moyenne** des ensembles (sont-ils petits ou énormes ?).

Méthodologie détaillée :

- **Score de non-conformité :** Pour chaque observation i de l'ensemble de calibration, récupérer la probabilité softmax $\hat{p}_{y_i}$ associée à la vraie espèce y_i depuis `ai_scores_all.csv`, puis calculer $S_i = 1 - \hat{p}_{y_i}$.
- **Quantile conformal :** Calculer $\hat{q} = \text{Quantile}\left(\{S_1, \dots, S_n\}, \frac{\lceil (n+1)(1-\alpha) \rceil}{n}\right)$. La correction d'échantillon fini garantit la couverture exacte $\geq 1 - \alpha$ pour tout n .
- **Inférence sur le test :** Pour chaque observation de test $\mathbf{x}$, construire l'ensemble de prédiction $\mathcal{C}(\mathbf{x}) = \{y : \hat{p}(y | \mathbf{x}) \geq 1 - \hat{q}\}$.
- **Évaluation :**
 - **Couverture marginale :** taux global de succès $\widehat{\text{Cov}} = \frac{1}{n_{\text{test}}} \sum_i \mathbf{1}\{y_i \in \mathcal{C}(\mathbf{x}_i)\}$.
 - **Taille moyenne des ensembles :** $|\overline{\mathcal{C}}| = \frac{1}{n_{\text{test}}} \sum_i |\mathcal{C}(\mathbf{x}_i)|$.

Livraison : `scripts/03_marginal_conformal.py`.

Résultat attendu : Une couverture proche de 95% (cible théorique). Si elle est plus basse (ex: 91%), cela révèle un biais lié aux données et justifie la Phase 3 (correction).

Phase 3 : Méthode PAS pour le long tail

Objectif : Résoudre le problème de la Longue Traîne en appliquant la méthode PAS (Partitioned Adaptive Set).

Données à utiliser : `observations_experts.csv`, `ai_scores_all.csv`, `calibration_50.csv`, `test_50.csv`.

Tâches techniques :

- **Groupement par rareté :** En utilisant les stats descriptives, créer des groupes d'espèces (ex: Groupe "Rare" si $n < 10$ images, Groupe "Commun" sinon).
- **Calibration par groupe :** Appliquer la logique de la Phase 2 mais de façon **indépendante** pour chaque groupe. On aura donc un $\hat{q}_{\text{rare}}$ et un $\hat{q}_{\text{commun}}$.
- **Analyse comparative :** Comparer la couverture des espèces rares entre la méthode Baseline (Phase 2) et la méthode PAS. L'hypothèse est que PAS donne une meilleure couverture sur la "tail".

Méthodologie détaillée :

- **Définition des groupes :** Soit n_k le nombre d'observations en calibration pour l'espèce k . On définit la fonction de groupement $g(k) = \text{rare}$ si $n_k < 10$, sinon $g(k) = \text{commun}$.
- **Calibration par groupe :** Pour chaque groupe $m \in \{\text{rare}, \text{commun}\}$, calculer $\hat{q}_m = \text{Quantile} \left(\{S_i : g(y_i) = m\}, \frac{\lceil (n_m + 1)(1 - \alpha) \rceil}{n_m} \right)$.
- **Inférence avec PAS :** Pour une nouvelle observation $\mathbf{x}$, l'ensemble de prédiction est $\mathcal{C}_{\text{PAS}}(\mathbf{x}) = \{y : \hat{p}(y | \mathbf{x}) \geq 1 - \hat{q}_{g(y)}\}$. Le seuil utilisé dépend du groupe de l'espèce candidate.
- **Comparaison Baseline vs PAS :** Calculer pour les deux méthodes la couverture marginale (devrait être similaire $\approx 1 - \alpha$), la couverture macro (PAS devrait gagner significativement), la couverture stratifiée par fréquence d'espèce et la taille moyenne des ensembles.

Visualisation attendue : Graphique en boîtes ou histogramme comparant la distribution des couvertures par espèce entre la méthode Baseline et PAS, mettant en évidence l'amélioration sur les espèces rares.

Livrable : `scripts/04_pas_method.py`.

Résultat attendu : PAS maintient une couverture macro élevée même sur les espèces qui ont très peu de photos, contrairement à la méthode standard. La taille des ensembles reste raisonnable (contrairement à la méthode conditionnelle stricte qui sera explorée dans la Partie 2).