

Les Phases de la Partie 3

Dossou Agossou, Firdaousse Karimou, Moussa Diagne

Mai 2026

Table des matières

1	Contexte	2
2	Phase 1 : Analyse de sensibilité sur α (multi-seuils)	3
2.1	Objectif	3
2.2	Données à utiliser	3
2.3	Méthodologie détaillée	3
2.3.1	Valeurs de α à tester	3
2.3.2	Pour chaque valeur de α , calculer :	3
2.3.3	Vérifications attendues	3
2.4	Visualisations à produire	3
2.5	Livrable	4
2.6	Résultat attendu	4
3	Phase 2 : PAS sur l'exemple synthétique déséquilibré	5
3.1	Objectif	5
3.2	Données à utiliser	5
3.3	Méthodologie détaillée	5
3.3.1	Génération des données déséquilibrées	5
3.3.2	Partitionnement	5
3.3.3	Méthodes à appliquer	5
3.3.4	Métriques à calculer	5
3.3.5	Points de vérification	5
3.4	Visualisations à produire	6
3.5	Livrable	6
3.6	Résultat attendu	6
4	Phase 3 : Traitement des observations manquantes	7
4.1	Objectif	7
4.2	Données à utiliser	7
4.3	Rappel du problème	7
4.4	Méthodologie détaillée	7
4.4.1	Les 3 stratégies à comparer	7
4.4.2	Pour chaque stratégie, calculer :	8
4.4.3	Tableau de comparaison attendu	8
4.5	Visualisations à produire	8
4.6	Discussion attendue	8
4.7	Livrable	8
4.8	Résultat attendu	8
5	Références	9

1 Contexte

Les retours du prof sont les suivants :

1. *“Changer un peu les seuils et ne gardez pas que 95% pour y voir plus clair.”*
2. *“Pour PAS est ce que la couverture est ok sur votre exemple synthétique ?”*
3. *“Essayer de proposer un traitement pour les cas où l’on a pas le score de la bonne classe (car trop bas...).”*

2 Phase 1 : Analyse de sensibilité sur α (multi-seuils)

2.1 Objectif

Tester la CP Standard et PAS avec **plusieurs valeurs de α** sur les données réelles Pl@ntNet, et vérifier que la couverture observée suit bien la couverture cible dans chaque cas. Cela permet de confirmer que notre implémentation est robuste et que les résultats ne dépendent pas du choix $\alpha = 0.05$.

2.2 Données à utiliser

- `calibration.csv` (10 812 observations)
- `test.csv` (10 812 observations)
- `ai_scores_all.csv` (scores softmax)

2.3 Méthodologie détaillée

2.3.1 Valeurs de α à tester

Nous testons les valeurs suivantes :

α	Couverture cible ($1 - \alpha$)	Interprétation
0.01	99%	Très conservateur
0.10	90%	Modéré
0.20	80%	Permissif

2.3.2 Pour chaque valeur de α , calculer :

1. **CP Standard (avec correction du biais) :**
 - Calculer les scores de non-conformité $S_i = 1 - \hat{f}(x_i)_{y_i}$ sur la calibration (avec $S_i = 1.0$ pour les observations manquantes).
 - Calculer le quantile corrigé $\hat{q}_\alpha$.
 - Construire les ensembles de prédiction sur le test.
 - Mesurer : couverture marginale, couverture macro, taille moyenne des ensembles.
2. **PAS (avec correction du biais) :**
 - Mêmes étapes, mais avec un quantile par groupe (Rare / Commun).
 - Mesurer les mêmes métriques.

2.3.3 Vérifications attendues

- Pour chaque α , la couverture marginale des deux méthodes doit être $\geq 1 - \alpha$.
- La taille des ensembles doit **augmenter** quand α diminue (plus de garantie $\Rightarrow$ ensembles plus larges).
- La couverture macro de PAS doit être au moins aussi bonne que celle de Standard.

2.4 Visualisations à produire

1. **Graphique couverture observée vs couverture cible** : un scatter plot avec la droite $y = x$ (couverture parfaite). Chaque point correspond à un α , avec une couleur par méthode (Standard / PAS). Si les points sont sur la droite, l'implémentation est correcte.
2. **Graphique taille moyenne vs α** : montrer le compromis couverture-efficacité. Deux courbes (Standard / PAS).
3. **Tableau récapitulatif** :

α	Cible	Couv. marg. Std	Couv. marg. PAS	Couv. macro Std	Couv. macro PAS	Taille Std	Taille PAS
0.01	99%	?	?	?	?	?	?
0.05	95%	?	?	?	?	?	?
0.10	90%	?	?	?	?	?	?
0.20	80%	?	?	?	?	?	?

2.5 Livrable

- Script : `analyse_sensibilite_alpha.py`
- Figures : `fig_couverture_vs_cible.png`, `fig_taille_vs_alpha.png`
- CSV : `resultats_multi_alpha.csv`

2.6 Résultat attendu

Les couvertures marginales suivent la cible pour les deux méthodes, la taille des ensembles décroît avec α , et PAS maintient une couverture macro légèrement supérieure à Standard sur les espèces communes.

3 Phase 2 : PAS sur l'exemple synthétique déséquilibré

3.1 Objectif

Le sanity check de la Partie 2 (Phase 1) ne testait que la CP Standard sur des classes **équilibrées**. Le prof demande de vérifier que PAS fonctionne aussi sur un exemple synthétique, cette fois avec des classes **déséquilibrées** simulant la longue traîne de Pl@ntNet.

3.2 Données à utiliser

Données synthétiques générées artificiellement (pas de fichier externe).

3.3 Méthodologie détaillée

3.3.1 Génération des données déséquilibrées

Créer un mélange de 10 gaussiennes en 2D, mais avec un **déséquilibre** entre les classes :

Classe	Type	Observations	Analogie Pl@ntNet
0 à 4	Commune	1 500 par classe	Espèces bien représentées
5 à 9	Rare	50 par classe	Espèces de la longue traîne
Total		7 750	

Les centres restent disposés en cercle (rayon = 4) avec variance unitaire.

3.3.2 Partitionnement

Ensemble	Taille	Méthode
Bloc A (entraînement)	50%	Entraîner la régression logistique
$D_{\text{calibration}}$	25%	Calibrer la CP
D_{test}	25%	Évaluer la couverture

Le split doit être **stratifié** pour maintenir les proportions de chaque classe.

3.3.3 Méthodes à appliquer

1. **CP Standard** : un seul quantile $\hat{q}$ global.
2. **PAS** : deux quantiles, $\hat{q}_{\text{rare}}$ (classes 5–9) et $\hat{q}_{\text{commun}}$ (classes 0–4).

3.3.4 Métriques à calculer

Pour chaque méthode :

- **Couverture marginale** : $\frac{1}{n_{\text{test}}} \sum_i \mathbb{1}\{y_i \in C(x_i)\}$
- **Couverture macro** : $\frac{1}{K} \sum_{k=1}^K \text{Couv}_k$
- **Couverture par groupe** : couverture marginale et macro séparément pour les classes communes et rares.
- **Taille moyenne** des ensembles de prédiction.

3.3.5 Points de vérification

- Les deux méthodes doivent avoir une couverture marginale $\approx 95\%$.
- PAS doit avoir une **meilleure couverture macro** que Standard, car les classes rares (sous-représentées) bénéficient d'un seuil adapté.
- Sur les classes **rares**, PAS doit améliorer la couverture par rapport à Standard.

3.4 Visualisations à produire

1. **Nuage de points 2D** coloré par classe, montrant le déséquilibre.
2. **Barplot couverture par classe** : Standard vs PAS, avec la ligne cible à 95%. On devrait voir que Standard sous-couvre les classes rares et que PAS corrige cela.
3. **Barplot marginale vs macro** : similaire à la Phase 2 de la Partie 2, mais sur données synthétiques.
4. **Tableau récapitulatif** :

Métrique	Standard	PAS
Couverture marginale	?	?
Couverture macro	?	?
Couv. marginale Rares	?	?
Couv. marginale Communes	?	?
Couv. macro Rares	?	?
Couv. macro Communes	?	?
Taille moyenne	?	?

3.5 Livrable

- Script : `toy_example_desequilibre.py`
- Figures : `fig_toy_desequilibre.png`, `fig_toy_couverture_par_classe.png`
- CSV : `resultats_toy_desequilibre.csv`

3.6 Résultat attendu

- CP Standard : couverture marginale $\approx 95\%$, mais couverture macro plus basse (les classes rares tirent vers le bas).
- PAS : couverture marginale $\approx 95\%$, et couverture macro **supérieure** à Standard grâce à l'adaptation du seuil pour les classes rares.

Ce résultat validera PAS sur un cadre contrôlé avant son application aux données réelles.

4 Phase 3 : Traitement des observations manquantes

4.1 Objectif

Proposer et comparer plusieurs **stratégies de traitement** pour les observations dont la vraie espèce est absente du fichier `ai_scores_all.csv` (score softmax < 0.001). Le prof demande d'aller au-delà du simple $S_i = 1.0$ et de proposer des alternatives raisonnées.

4.2 Données à utiliser

- `calibration.csv` (10 812 observations)
- `test.csv` (10 812 observations)
- `ai_scores_all.csv` (scores softmax)

4.3 Rappel du problème

Sur les 10 812 observations de calibration, **410 (3,8%)** ont leur vraie espèce absente du fichier de scores car le modèle leur a attribué un score softmax inférieur au seuil de troncature de 0.001. Ignorer ces observations biaise le quantile vers le bas et fait chuter la couverture de 95% à 91%.

4.4 Méthodologie détaillée

4.4.1 Les 3 stratégies à comparer

Stratégie A : $S_i = 1.0$ (approche actuelle)

On considère que le score softmax de la vraie espèce est nul (ou négligeable). Donc :

$$S_i = 1 - 0 = 1.0$$

C'est l'approche la plus **conservative** : on traite l'échec du modèle comme maximal. C'est une borne supérieure du vrai score de non-conformité.

Stratégie B : $S_i = 1 - 0.001 = 0.999$

On considère que le score softmax de la vraie espèce est **exactement** au seuil de troncature (0.001). Donc :

$$S_i = 1 - 0.001 = 0.999$$

C'est une borne **inférieure** : le vrai score est quelque part entre 0 et 0.001, et on prend la valeur maximale possible. En pratique, la différence avec la Stratégie A est minime (0.001), mais c'est conceptuellement différent.

Stratégie C : Exclusion avec correction du quantile

On exclut les observations manquantes du calcul, mais on ajuste le quantile pour compenser le biais. L'idée est d'utiliser une borne de couverture plus conservatrice :

$$\hat{q} = \text{Quantile} \left(\{S_1, \dots, S_{n'}\}, \frac{\lceil (n+1)(1-\alpha) \rceil}{n'} \right)$$

où n est le nombre total d'observations (y compris manquantes) et n' est le nombre d'observations conservées. En utilisant n au numérateur et n' au dénominateur, on pousse le quantile vers le haut pour compenser les observations exclues.

4.4.2 Pour chaque stratégie, calculer :

Appliquer la CP Standard avec chaque stratégie de traitement et mesurer :

- Le quantile $\hat{q}$ obtenu.
- La couverture marginale sur le test set.
- La couverture macro sur le test set.
- La taille moyenne des ensembles de prédiction.

4.4.3 Tableau de comparaison attendu

Métrique	Strat. A ($S_i = 1.0$)	Strat. B ($S_i = 0.999$)	Strat. C (exclusion corrigée)
$n_{\text{calibration}}$ utilisé	10 812	10 812	10 402
$\hat{q}$	?	?	?
Couverture marginale	?	?	?
Couverture macro	?	?	?
Taille moyenne	?	?	?

4.5 Visualisations à produire

1. **Barplot triple** : couverture marginale pour les 3 stratégies, avec la cible à 95%.
2. **Barplot triple** : taille moyenne des ensembles pour les 3 stratégies.
3. **Distribution des scores de non-conformité** : superposer les 3 distributions (ou les afficher côte à côte) pour montrer comment chaque stratégie modifie la queue droite de la distribution.

4.6 Discussion attendue

La discussion doit aborder les points suivants :

- **Stratégies A et B** donnent des résultats quasi identiques car la différence (0.001) est négligeable devant l'échelle des scores. Cela montre que le choix exact de la valeur de remplacement importe peu.
- **Stratégie C** est plus risquée car elle repose sur une correction ad hoc du niveau du quantile. Elle peut sous-estimer ou surestimer la couverture selon la proportion d'observations manquantes.
- **Recommandation** : la Stratégie A ($S_i = 1.0$) est la plus simple, la plus conservative, et la plus fidèle à l'interprétation statistique ("le modèle a échoué").

4.7 Livrable

- Script : `traitement_observations_manquantes.py`
- Figures : `fig_comparaison_strategies.png`, `fig_distribution_strategies.png`
- CSV : `resultats_strategies_manquantes.csv`

4.8 Résultat attendu

Les Stratégies A et B donnent des résultats quasi identiques (couverture $\approx 95\%$, taille ≈ 2.6). La Stratégie C donne des résultats différents mais potentiellement moins fiables. La conclusion est que $S_i = 1.0$ est un choix robuste et bien justifié.

5 Références

- Angelopoulos, A. N. & Bates, S. (2021). *A Gentle Introduction to Conformal Prediction and Distribution-Free Uncertainty Quantification*. arXiv :2107.07511.
- Ding, T., Fermanian, J.-B. & Salmon, J. (2025). *Conformal Prediction for Long-Tailed Classification*. arXiv :2507.06867.
- Lefort, T. et al. (2024). *Pl@ntNet collaborative learning : South-Western-Europe dataset*. arXiv :2406.03356.