

Les Phases de la Partie 2

Pl@ntNet

2026-04-25

Phase 1 : Sanity Check sur dataset synthétique

Objectif : Valider mathématiquement notre implémentation de la Conformal Prediction du travail effectué précédemment, en le testant sur un dataset où on contrôle tout.

Si on obtient 95% ici, le code est validé.

Le travail consiste à réutiliser nos scripts précédent sur des données simulées.

Données : Données synthétiques (artificielles) générées avec `sklearn.datasets.make_blobs`

Modèle : Regression Logistique Multinomiale (avec `scikit-learnLogisticRegression(multi_class='multinomial')`)

Méthodologie détaillée :

- **Génération :** Créer un cadre de classification simplifié (un mélange de gaussienne), ou nous contrôlons le processus génératif (disons avec 10 classes). Générer 10 000 points (observations) avec `sklearn.datasets.make_blobs` ($N = 10000$ observations, 2 variables explicatives (X_1, X_2) et 10 classes)
- **Shuffle/Split initial :** Diviser les données générées en deux blocs de 5000 (Bloc A et Bloc B)
- **Entraînement :** Entraîner une `LogisticRegression(multi_class='multinomial')` sur le Bloc A
- **Shuffle/Split (50%/50%) :** Prendre le Bloc B et le diviser en `D_calibration` (2500 observations) et `D_test` (2500 observations)
- **Calculer les scores de non-conformité :** ** Pour chaque observation de `D_calibration`, récupérer la probabilité prédite par la logistique pour la **vraie** classe (p_{true}). Calculer le score de non-conformité : $S_i = 1 - p_{true}$.
- **Quantile :** Calculer $\hat{q}$ comme le quantile $(n + 1)(1 - \alpha)/n$ des S_i .
- **Inférence (Test) :** Pour chaque observation de `D_test`, l'ensemble de prédiction contient toutes les classes dont la probabilité $\geq 1 - \hat{q}$.

Ensemble de prediction: $\mathcal{C}(x) = \{y : \hat{p}(y|x) \geq 1 - \hat{q}\}$

Vérification : Calculer le % de fois où la vraie classe est dans l'ensemble.

Résultat attendu : 95% de couverture (94% à 96% acceptable)

Phase 2 : Analyse de la Performance (Couverture marginale vs Couverture macro)

Objectif : Répondre à l'exigence du prof sur la différence de performance entre Standard CP et PAS, surtout sur les espèces rares.

Données à utiliser : `observations_expert.csv`, `ai_scores_all.csv`, `calibrations_50.csv` et `tests_50.csv`

Calculs de couverture :

- **Couverture Marginale :** Taux de succès global sur l'ensemble du fichier test (les espèces communes vont dominer ce chiffre).
- **Couverture Macro :** Pour chaque espèce, calculer son taux de succès individuel, puis faire la moyenne de ces taux.

Comparaison Standard vs PAS : Montrer que PAS maintient une **couverture macro** élevée même sur les espèces qui ont très peu de photos, contrairement à la méthode standard.

Visualiser le détail par espèce : Graphique en boîtes ou histogramme de la distribution des couvertures par espèce.

Phase 3 : Correction du Biais et test de la couverture conditionnelle

Objectif : Atteindre les 95% de couverture marginale et prouver l'inefficacité de la CP conditionnelle.

Données à utiliser : `observations_experts.csv` et `ai_scores_all.csv`.

Méthodologie détaillée :

*** Le correctif :**

- Dans `ai_scores_all.csv`, certaines espèces réelles sont absentes (car leur score est < 0.001).
- **Action :** Pour ces lignes, ne pas les supprimer ! Assigner un score de non-conformité $S_i = 1$ (car la confiance de l'IA sur la bonne réponse était nulle).
- Recalculer le quantile avec ces valeurs. Cela devrait faire remonter votre couverture globale de 91% à 95%.

*** Test de la CP Conditionnelle :**

- Implémenter une version où le seuil $\hat{q}$ change selon le score softmax de l'IA (S-split).
- **Mesure d'efficacité :** Calculer la taille moyenne des "Prediction Sets".
- **Objectif :** Montrer que cette méthode produit des ensembles contenant beaucoup trop d'espèces (ex: 50 espèces au lieu de 2), ce qui rend la prédiction inutile pour l'utilisateur.
- **Visualiser :** Graphique de la distribution des tailles d'ensembles pour les trois méthodes : CP standard, PAS, Conditionnelle