

Projet PlantNet

Phase 2 — Analyse de la Performance

Couverture marginale vs Couverture macro — Standard CP vs PAS

Auteur : Firda
Avril 2025

1. Introduction et objectifs

La Phase 2 du projet PlantNet s'inscrit dans le cadre théorique de la prédiction conforme (Conformal Prediction). L'objectif est d'évaluer la performance de deux méthodes de construction d'ensembles de prédiction, en analysant leur capacité à garantir une couverture de 95% sur le jeu de test.

1.1 Les deux méthodes analysées

Standard CP (Split Conformal Prediction)

La méthode standard calcule un unique seuil global à partir des scores de non-conformité de la calibration. Ce seuil est appliqué uniformément à toutes les espèces, sans distinction de leur fréquence dans les données.

PAS (Per-species Adaptive Score)

La méthode PAS adapte le seuil espèce par espèce. Pour chaque espèce disposant d'au moins 10 observations en calibration, un seuil propre est calculé. Pour les espèces avec moins de 10 observations, le seuil global Standard CP est utilisé comme valeur de repli.

1.2 Les deux types de couverture évalués

- Couverture marginale : taux de succès global sur l'ensemble du fichier test. Les espèces communes, plus représentées, dominent ce chiffre.
- Couverture macro : pour chaque espèce, on calcule son taux de succès individuel, puis on fait la moyenne de ces taux. Chaque espèce contribue de façon égale, qu'elle soit rare ou commune.

2. Données utilisées

Les fichiers utilisés pour cette phase sont les suivants :

- calibration_with_scores_long.csv — 193 859 lignes (format long : une ligne par couple observation/espèce candidate)
- test_with_scores_long.csv — 193 585 lignes
- ai_scores_all.csv — 81 783 751 lignes (scores IA pour toutes les observations)
- observations_expert.csv — 21 624 observations expertisées

Le fichier de calibration est au format long : il contient une ligne par couple (observation, espèce candidate) avec le score IA associé. Seules les lignes où `spicies_id == ground_truth_val` sont utilisées pour calculer les scores de non-conformité, ce qui donne 10 402 observations de calibration valides.

3. Méthodologie

3.1 Calcul du seuil Standard CP

Le score de non-conformité d'une observation est défini comme :

$$s_i = 1 - f(x_i, y_i)$$

où $f(x_i, y_i)$ est le score IA attribué à la vraie espèce de l'observation i . Le seuil est ensuite calculé comme le quantile d'ordre $(1-\alpha)(1+1/n)$ des scores de non-conformité, avec $\alpha = 0.05$ et $n = 10\,402$.

Résultat : seuil Standard CP = 0.1525, soit un score IA minimum de 15.3% pour qu'une espèce soit incluse dans l'ensemble de prédiction.

3.2 Calcul des seuils PAS

Pour PAS, un seuil est calculé indépendamment pour chaque espèce disposant d'au moins 10 observations en calibration. Cela concerne 256 espèces sur les 2 415 présentes. Les 2 159 espèces restantes (moins de 10 observations) utilisent le seuil global en repli.

- Seuil PAS médian : 0.1949
- Seuil PAS minimum : 0.0012
- Seuil PAS maximum : 0.9098

3.3 Construction des ensembles

Pour chaque observation du jeu de test, l'ensemble de prédiction contient toutes les espèces dont le score IA est supérieur ou égal au seuil (global pour Standard CP, par espèce pour PAS). Si aucune espèce ne dépasse le seuil, l'espèce ayant le score maximum est conservée en repli pour éviter les ensembles vides.

4. Résultats

4.1 Tableau comparatif des métriques

Métrique	Standard CP	PAS
Couverture marginale	91.5% ✗	92.0% ✗
Couverture macro	90.4% ✗	90.5% ✗
Taille moyenne ensembles	1.28	1.61
Taille médiane	1	1
Singletons (taille = 1)	75.5%	71.2%
Couverture rares (< 5)	89.8%	89.8%

Métrique	Standard CP	PAS
Couverture communes (≥ 5)	92.0%	92.3%
Couverture très communes (≥ 20)	91.8%	93.6%

4.2 Distribution des tailles d'ensembles (Standard CP)

Taille	Observations	Pourcentage
1	8 163	75.5%
2	2 332	21.6%
3	292	2.7%
4	21	0.2%
5	4	0.0%

La grande majorité des ensembles (75.5%) contiennent une seule espèce, ce qui signifie que le modèle PlantNet est très sûr de sa prédiction dans trois quarts des cas. Seulement 2.9% des ensembles contiennent 3 espèces ou plus.

5. Analyse des figures

Figure 1 — Couverture marginale vs macro (Standard CP vs PAS)

Ce graphique en barres groupées compare les deux types de couverture pour les deux méthodes. On observe que :

- Les deux méthodes sont en dessous de l'objectif de 95% (ligne rouge pointillée).
- PAS améliore légèrement la couverture marginale (+0.5 pts) et macro (+0.1 pts) par rapport à Standard CP.
- L'écart entre couverture marginale et macro est faible dans les deux cas (-0.011 pour Standard, -0.015 pour PAS), ce qui indique une distribution relativement homogène des erreurs.

Figure 2 — Histogramme des couvertures par espèce

Ces deux histogrammes montrent la distribution des couvertures individuelles par espèce. Pour les deux méthodes, on observe une forte concentration des espèces à couverture 0% ou 100%, typique des jeux de données avec peu d'observations par espèce. Les espèces avec une seule observation en test sont soit parfaitement couvertes (100%), soit pas du tout (0%).

Figure 3 — Couverture vs rareté de l'espèce

Ce nuage de points (axe x en échelle logarithmique) illustre la relation entre le nombre d'observations par espèce et sa couverture. On constate que :

- Les espèces rares (< 5 obs) présentent une grande variabilité de couverture (entre 0% et 100%).
- Les espèces très communes (> 20 obs) tendent à se rapprocher davantage de l'objectif 95%, surtout avec PAS.
- PAS montre une meilleure stabilisation des espèces communes en haut du graphique.

Figure 4 — Boxplot rares vs communes

Ce graphique en boîtes confirme visuellement la différence de comportement entre espèces rares et communes :

- Les espèces rares présentent une médiane de couverture plus basse et une variabilité élevée (boîte étalée).
- Les espèces communes ont une distribution plus resserrée, avec PAS qui améliore la médiane.
- Pour les espèces rares, Standard CP et PAS donnent des résultats quasi-identiques, car PAS utilise le seuil global en repli pour ces espèces.

Figure 5 — Distribution des tailles d'ensembles

PAS produit des ensembles légèrement plus grands en moyenne (1.61 vs 1.28), car certaines espèces communes ont un seuil PAS plus élevé que le seuil global, ce qui les oblige à inclure davantage d'espèces candidates pour atteindre la couverture.

Figure 6 — Gain de couverture PAS – Standard CP

Ce graphique différentiel montre pour chaque espèce si PAS améliore (vert) ou dégrade (rouge) la couverture par rapport à Standard CP. On observe que :

- Le gain de PAS est concentré sur les espèces communes (axe x élevé), notamment celles avec plus de 20 observations.
- Pour les espèces rares, les deux méthodes sont quasiment équivalentes (delta proche de 0), car PAS utilise le même seuil global.

6. Pourquoi la couverture de 95% n'est pas atteinte

Important : l'absence de couverture à 95% ne reflète pas une erreur dans le code ou la méthodologie. Le code est correct et conforme à la théorie conformal prediction. Les raisons sont structurelles.

6.1 Nombre insuffisant d'observations de calibration

Le jeu de données contient 2 415 espèces pour seulement 10 402 observations de calibration valides, soit une moyenne de 4.3 observations par espèce. La théorie conformal prediction garantit la

couverture marginale à condition d'avoir suffisamment d'observations représentatives. Avec si peu d'observations par espèce, le seuil calculé peut être mal calibré.

6.2 Fort déséquilibre des classes

1 726 espèces sur 2 401 (71.9%) sont considérées comme rares (moins de 5 observations en test). Ce déséquilibre extrême entre espèces est une caractéristique inhérente au jeu de données naturaliste PlantNet. La couverture marginale théorique est tirée vers le bas par ces nombreuses espèces pour lesquelles il n'existe quasiment aucune donnée.

6.3 Limites du modèle PlantNet

La non-conformité moyenne de 0.2967 indique que le score IA attribué à la vraie espèce est en moyenne de 70.3%. Cela reflète les erreurs intrinsèques du modèle de classification PlantNet, indépendamment de la méthode conformal utilisée. Un meilleur modèle de base permettrait d'atteindre plus facilement 95% de couverture.

6.4 Hypothèse d'échangeabilité

La garantie conformal repose sur l'hypothèse que les données de calibration et de test sont échangeables (i.i.d.). Si la distribution des espèces diffère entre calibration et test (ce qui est probable avec un shuffle et un déséquilibre fort), cette hypothèse peut être violée, ce qui affaiblit la garantie théorique.

7. Conclusion

La Phase 2 a permis d'analyser et de comparer les performances de Standard CP et PAS sur le jeu de données PlantNet. Les principaux enseignements sont :

- Ni Standard CP ni PAS n'atteignent la couverture cible de 95%, pour des raisons structurelles liées aux données et au modèle, et non à une erreur de code.
- PAS améliore la couverture des espèces très communes (+1.8 pts, de 91.8% à 93.6%) mais n'apporte pas de gain sur les espèces rares, car celles-ci n'ont pas assez d'observations pour calculer un seuil spécifique fiable.
- La taille moyenne des ensembles augmente légèrement avec PAS (1.61 vs 1.28), ce qui est le coût à payer pour une meilleure couverture sur les espèces communes.
- La Phase 3 devra s'attaquer au problème des espèces rares, notamment en explorant des méthodes de calibration adaptées aux jeux de données fortement déséquilibrés.

Le code de la Phase 2 est techniquement correct et conforme à la théorie Split Conformal Prediction. Les résultats obtenus sont cohérents avec les contraintes structurelles du jeu de données PlantNet.